

UNIVERSIDADE ESTADUAL DO SUDOESTE DA BAHIA

Curso de Sistemas de Informação

Introdução à Estatística Computacional

**SEGMENTAÇÃO DE CLIENTES DE VAREJO ONLINE: UMA ANÁLISE DE
DADOS MULTIVARIADOS, TÉCNICAS DE AGRUPAMENTO E SIMULAÇÃO
DE MONTE CARLO**

Trabalho da terceira unidade - Base de dados Online Retail (UCI Machine Learning Repository)

Alunos: Eduardo Meira, João Daví, João Francisco e Níxon Cruz

Professor: Guilherme Waldschmidt Pereira

Modalidade: Trabalho em grupo

Jequié - BA

2026

1. Introdução

Empresas de comércio eletrônico registram, a cada transação, um conjunto amplo de informações sobre o comportamento de compra de seus clientes. Quando analisadas de forma agregada, essas informações permitem identificar padrões de consumo, diferenciar perfis de clientes e orientar decisões de marketing, precificação e retenção. Este trabalho tem como objetivo aplicar técnicas de análise de dados multivariados, agrupamento (clustering) e simulação de Monte Carlo para identificar, comparar, interpretar e avaliar a estabilidade de segmentos de clientes presentes em uma base real de transações de varejo online.

A base de dados utilizada foi a Online Retail, disponibilizada publicamente pelo UCI Machine Learning Repository, contendo transações de uma loja online do Reino Unido entre 2010 e 2011. A unidade de análise adotada foi o cliente, identificado pela variável CustomerID, agregando-se as transações individuais em variáveis de comportamento de compra por cliente.

1.1 Pergunta de pesquisa

Quais segmentos de clientes podem ser identificados a partir de seus comportamentos de compra (frequência, valor gasto, quantidade adquirida e variedade de produtos), e o quão estáveis são esses segmentos diante de variações na amostra e na inicialização dos algoritmos?

1.2 Utilidade prática

A identificação de segmentos de clientes permite à empresa direcionar ações comerciais específicas para cada perfil - por exemplo, programas de fidelidade para clientes frequentes, abordagens de reativação para clientes esporádicos e atendimento diferenciado para clientes de alto volume (possivelmente revendedores ou compradores institucionais).

2. Metodologia

2.1 Base de dados e preparação

A base original continha registros de itens individuais de nota fiscal (InvoiceNo), incluindo código do produto (StockCode), descrição, quantidade (Quantity), data da transação (InvoiceDate), preço unitário (UnitPrice), identificador do cliente (CustomerID) e país (Country).

As seguintes transformações e filtros foram aplicados antes da agregação por cliente:

- Conversão da coluna InvoiceDate para o tipo data/hora;
- Criação da variável TotalPrice, calculada como $\text{Quantity} \times \text{UnitPrice}$;
- Remoção de compras canceladas, identificadas por números de nota fiscal iniciados pela letra "C" (convenção da própria base para estornos/cancelamentos);
- Remoção de registros sem CustomerID preenchido, uma vez que a unidade de análise é o cliente e transações sem identificação não podem ser atribuídas a nenhum indivíduo.

Após essas etapas, os dados foram agregados por CustomerID, resultando em uma base com 4.339 clientes distintos - valor superior ao mínimo de 100 observações exigido.

2.2 Variáveis analisadas

Foram construídas seis variáveis quantitativas por cliente, todas relacionadas ao comportamento de compra:

- Frequência: número de notas fiscais distintas emitidas para o cliente;
- Valor Total: soma de todas as compras do cliente, em libras esterlinas;
- Quantidade Total: soma de todos os itens adquiridos pelo cliente;
- Produtos Distintos: número de códigos de produto (StockCode) diferentes adquiridos;
- Valor Médio por Compra: Valor Total dividido pela Frequência;
- Quantidade Média por Compra: Quantidade Total dividida pela Frequência.

O identificador CustomerID foi mantido apenas como referência e não foi utilizado no cálculo das distâncias entre observações, conforme exigido no enunciado do trabalho.

2.3 Análise exploratória univariada

Para cada variável, foram calculadas medidas de tendência central (média, mediana, moda), de dispersão (desvio-padrão, variância, coeficiente de variação) e de posição (mínimo, máximo, primeiro e terceiro quartis). A Tabela 1 resume esses resultados.

Variável	Média	Mediana	Desvio-padrão	CV (%)	Mínimo	Máximo
Frequência	4,27	2,00	7,71	180,4	1	210
Valor Total (£)	2.053,79	674,45	8.988,25	437,6	0,00	280.206,02
Quantidade Total	1.194,21	379,00	5.055,60	423,3	1	197.491
Produtos Distintos	61,49	35,00	85,36	138,8	1	1.787
Valor Médio/Compra (£)	419,05	293,69	1.796,32	428,7	0,00	84.236,25
Quant. Média/Compra	256,31	161,75	1.325,94	517,3	1	74.215,00

Tabela 1 - Estatísticas descritivas das variáveis analisadas ($n = 4.339$ clientes).

Em todas as seis variáveis, a mediana é muito inferior à média, e o coeficiente de variação ultrapassa 100% - chegando a 517% na Quantidade Média por Compra. Esse padrão é uma assinatura estatística clássica de distribuições fortemente assimétricas à direita, com presença de valores extremos (outliers) muito acima da maioria das observações. O boxplot da variável Valor Total (Figura 1), representativo do padrão observado nas demais variáveis, ilustra esse comportamento: a caixa (que concentra 50% dos dados) é visualmente comprimida próxima de zero, enquanto uma quantidade expressiva de pontos aparece muito acima do limite superior do bigode.




Figura 1 - Boxplot da variável Valor Total, evidenciando forte assimetria à direita e presença de outliers.

Essa característica foi mantida como um achado relevante da análise exploratória, e não tratada por remoção automática de outliers, uma vez que (no contexto de varejo) clientes com valores muito acima da média frequentemente representam compradores institucionais ou revendedores, e não erros de registro. Essa decisão é retomada e discutida em detalhe na Seção 4 (Discussão), pois tem impacto direto nos resultados do agrupamento.

2.4 Análise exploratória multivariada

A Figura 2 apresenta o mapa de calor da matriz de correlação de Pearson entre as seis variáveis selecionadas.




Figura 2 - Mapa de calor da matriz de correlação entre as variáveis analisadas.

Os pares com maior correlação positiva foram Valor Médio por Compra e Quantidade Média por Compra ($r = 0,921$), Frequência e Produtos Distintos ($r = 0,692$), e Frequência com Valor Total e Quantidade Total ($r \approx 0,55$ em ambos os casos). Já Frequência apresentou correlação praticamente nula com Valor Médio por Compra ($r = 0,019$) e com Quantidade Média por Compra ($r = 0,010$), indicando que a frequência de compra não está relacionada ao valor médio gasto em cada transação - ou seja, comprar com frequência não implica gastar mais (ou menos) por compra.

A correlação elevada entre Valor Médio por Compra e Quantidade Média por Compra é esperada, já que ambas são derivadas da divisão por Frequência e tendem a crescer/diminuir de forma conjunta quando o preço unitário médio dos produtos do cliente é relativamente estável. Isso caracteriza uma possível redundância de informação entre essas duas variáveis, discutida na Seção 4.

A Figura 3 apresenta a dispersão entre Frequência e Valor Total, mostrando visualmente a presença de poucos clientes com valores extremamente altos em ambas as dimensões, destacados no canto superior direito, isolados da nuvem principal de pontos.




Figura 3 - Dispersão entre Frequência e Valor Total por cliente.

É importante reforçar que correlação não implica causalidade: a associação observada entre, por exemplo, Frequência e Produtos Distintos, não permite concluir que comprar com mais frequência causa a aquisição de mais produtos distintos - ambas podem ser reflexo de um comportamento geral de maior engajamento do cliente com a loja.

2.5 Seleção de variáveis e padronização

As seis variáveis descritas na Seção 2.2 foram mantidas para a etapa de agrupamento, conforme exigência mínima de seis variáveis quantitativas relacionadas a um mesmo contexto. Embora Valor Médio por Compra e Quantidade Média por Compra apresentem correlação elevada ($r = 0,921$), optou-se por não removê-las nesta primeira rodada de análise, pois representam conceitos gerenciais distintos (ticket médio monetário vs. volume médio de itens); essa decisão é revisitada como uma limitação na Seção 4.

Como as variáveis possuem escalas muito diferentes entre si (por exemplo, Frequência varia de 1 a 210, enquanto Valor Total varia de 0 a mais de 280 mil libras), todas foram padronizadas pelo escore z antes da aplicação dos algoritmos de agrupamento, de forma que cada variável passasse a ter média aproximadamente zero e desvio-padrão igual a um. Essa padronização é essencial em métodos baseados em distância, como o K-means, pois evita que variáveis de maior magnitude numérica dominem artificialmente o cálculo da distância euclidiana.

2.6 Medidas de distância

A distância euclidiana foi utilizada como medida de dissimilaridade nos três métodos de agrupamento aplicados (K-means, agrupamento hierárquico com método de Ward e DBSCAN), por ser adequada a variáveis quantitativas contínuas e amplamente empregada nesses algoritmos.

2.7 Técnicas de agrupamento aplicadas

Foram aplicadas três técnicas de agrupamento:

- K-means: testado para $K = 2$ a 10 , com seleção de $K = 3$ grupos para o modelo final, avaliado por meio do método do cotovelo e do coeficiente de silhueta;
- Agrupamento hierárquico: aplicado com o método de ligação de Ward e distância euclidiana, em uma amostra de 1.000 clientes (por restrição de memória do algoritmo, que possui complexidade quadrática), com dendrograma construído para apoiar a definição do número de grupos;

- DBSCAN: parâmetros `eps` e `min_samples` definidos com apoio do gráfico de distâncias aos k-vizinhos mais próximos e de uma varredura de combinações de parâmetros.

2.8 Avaliação dos agrupamentos

Os agrupamentos foram avaliados por meio do coeficiente de silhueta e do índice Davies–Bouldin, além do tamanho e da proporção de observações classificadas como ruído (no caso do DBSCAN).

2.9 Simulação de Monte Carlo

Para avaliar a estabilidade dos resultados de agrupamento, foi realizada uma simulação de Monte Carlo com $B = 200$ repetições, seguindo o procedimento:

- Definição de um agrupamento de referência, obtido com o K-means ($K = 3$) aplicado à base completa e padronizada;
- Em cada repetição: seleção aleatória de 80% dos clientes sem reposição, nova padronização da amostra, novo agrupamento com K-means e cálculo do Índice Rand Ajustado (ARI) em relação ao agrupamento de referência;
- Análise complementar de estabilidade frente a 30 sementes de inicialização diferentes, mantendo a base completa;
- Análise complementar de estabilidade frente a pequenas perturbações aleatórias (ruído gaussiano com desvio-padrão igual a 5% do desvio-padrão de cada variável) adicionadas aos dados originais;
- Construção de uma matriz de coagrupamento em uma subamostra de 300 clientes, estimando a proporção de repetições em que cada par de clientes permaneceu no mesmo grupo.

3. Resultados

3.1 Escolha do número de grupos (K-means)

A Figura 4 apresenta o método do cotovelo (WCSS por número de grupos) e a Figura 5 apresenta o coeficiente de silhueta médio para K entre 2 e 10.




Figura 4 - Método do cotovelo (WCSS) para K de 2 a 10.




Figura 5 - Coeficiente de silhueta médio para K de 2 a 10.

Um resultado chamou atenção: o coeficiente de silhueta permaneceu extremamente alto (acima de 0,90) e praticamente constante para todos os valores de K testados, e a curva do cotovelo apresenta uma queda abrupta logo em $K = 2$, seguida de estabilização quase completa. Esse padrão não é o comportamento “ideal” esperado (uma curva de silhueta com pico bem definido em um K específico); ele é, na verdade, uma evidência de que o agrupamento está sendo dominado por poucos pontos extremamente distantes do restante da base - os mesmos outliers identificados na análise univariada da Seção 2.3. Qualquer valor de K acima de 1 consegue isolar esses poucos pontos extremos do restante, o que já é suficiente para produzir uma silhueta artificialmente alta, independentemente de existir uma estrutura de agrupamento genuína dentro do grande grupo de clientes “comuns”. Esse achado é retomado com mais profundidade na Seção 4.

Ainda assim, seguindo a especificação do trabalho de utilizar $K = 3$ para fins de interpretação e comparabilidade entre métodos, o modelo final de K-means foi treinado com três grupos.

3.2 Perfil dos grupos - K-means ($K = 3$)

Grupo	n	% da base	Interpretação
0	4.321	99,59%	Clientes “comuns” (massa principal da base)
1	2	0,05%	Clientes extremos (megacompradores)
2	16	0,37%	Clientes de alto volume/alta frequência

Tabela 2 - Tamanho dos grupos obtidos pelo K-means ($K = 3$).

Variável (mediana)	Grupo 0	Grupo 1	Grupo 2
Frequência	2,0	1,5	57,5
Valor Total (£)	668,43	122.828,05	73.839,20
Quantidade Total	378	77.606	58.114
Produtos Distintos	35	2	601,5
Valor Médio/Compra (£)	292,24	80.709,93	1.717,48
Quant. Média/Compra	161,0	57.356,75	1.060,59

Tabela 3 - Perfil mediano de cada grupo (K-means, $K = 3$). Medianas foram usadas por serem mais robustas à assimetria observada.

O Grupo 0 concentra 99,59% dos clientes e reúne o perfil “típico” da base: poucas compras (mediana de 2 notas fiscais), valor total mediano de £668,43 e 35 produtos distintos adquiridos em mediana. O Grupo 1, com apenas dois clientes, reúne compradores com gasto extremamente elevado (mediana de £122.828,05) e baixa variedade de produtos (apenas 2 produtos distintos cada) - um padrão compatível com clientes que compram grandes quantidades de poucos itens, possivelmente para revenda ou uso institucional. O Grupo 2, com 16 clientes, reúne compradores de alta frequência (mediana de quase 58 compras) e ampla variedade de produtos (mediana de 601,5 produtos distintos), sugerindo um perfil de revendedor de catálogo amplo.

3.3 Agrupamento hierárquico

A Figura 6 apresenta o dendrograma obtido pelo método de Ward com distância euclidiana, em uma amostra de 1.000 clientes.




Figura 6 - Dendrograma do agrupamento hierárquico (método de Ward, amostra de 1.000 clientes).

O corte do dendrograma em três grupos (mesmo número definido para o K-means, para fins de comparabilidade) produziu um coeficiente de silhueta de 0,925 e índice Davies–Bouldin de 0,530, calculados sobre a mesma amostra utilizada na construção do dendrograma. O padrão observado no dendrograma reforça o achado da Seção 3.1: a primeira grande divisão do dendrograma já isola um pequeno número de observações muito distantes das demais, e apenas divisões subsequentes começam a segmentar a massa principal de clientes.

3.4 DBSCAN

A Figura 7 apresenta o gráfico de distâncias ao 5º vizinho mais próximo (k-distance plot), utilizado para apoiar a escolha do parâmetro eps.




Figura 7 - Gráfico das distâncias aos vizinhos (k-distance plot), com $\text{min_samples} = 5$.

A curva não apresenta um “cotovelo” muito nítido, o que é consistente com uma base cuja densidade varia fortemente (nuvem principal muito densa e outliers muito esparsos). Foi realizada uma varredura de combinações de eps (0,3 / 0,5 / 0,7 / 1,0) e min_samples (5 / 10 / 15); os resultados estão resumidos na Tabela 4.

eps	min_samples	Grupos	Ruído (n)
0,3	5	2	350
0,3	10	1	412
0,3	15	2	484
0,5	5	2	177
0,5	10	2	214
0,5	15	1	246
0,7	5	1	116
0,7	10	1	140
1,0	5	1	74

Tabela 4 - Teste de combinações de parâmetros do DBSCAN (seleção parcial).

A combinação eps = 0,5 e min_samples = 5 foi adotada por produzir dois grupos bem definidos com uma proporção de ruído moderada (4,08% da base), suficiente para isolar observações atípicas sem descartar uma fração excessiva dos dados. Com esses parâmetros, o DBSCAN identificou 4.157 clientes no maior grupo, 5 clientes em um segundo grupo minoritário e 177 clientes (4,08%) classificados como ruído.

3.5 Comparação entre os métodos

Método	Grupos	Silhueta	Davies-Bouldin	Ruído (n)	Ruído (%)
K-means	3	0,944	0,590	0	0,00%
Hierárquico (amostra)	3	0,925	0,530	0	0,00%
DBSCAN	2	0,764	0,224	177	4,08%

Tabela 5 - Comparação entre os três métodos de agrupamento aplicados.

Em termos puramente numéricos, o K-means apresentou a maior silhueta (0,944), seguido de perto pelo hierárquico (0,925); o DBSCAN apresentou silhueta mais baixa (0,764), mas o menor (melhor) índice Davies–Bouldin (0,224). Como discutido na Seção 4, essas métricas devem ser interpretadas com cautela neste caso específico, dado que a alta silhueta do K-means e do hierárquico decorre majoritariamente da separação de poucos outliers extremos, e não de uma segmentação comportamental refinada da maioria dos clientes.

A distribuição do coeficiente de silhueta por observação, para o K-means, é apresentada na Figura 8. Apenas 3 clientes (0,07% da base) apresentaram silhueta negativa, indicando atribuição possivelmente inadequada ao grupo.




Figura 8 - Distribuição da silhueta por grupo (K-means, K = 3).

3.6 Simulação de Monte Carlo

A Tabela 6 resume os resultados da simulação de reamostragem (B = 200 repetições, 80% da base em cada repetição, comparadas ao agrupamento de referência via Índice Rand Ajustado - ARI).

Estatística	Valor
ARI médio	0,9032
ARI mediana	0,9674
ARI desvio-padrão	0,2015
ARI mínimo	0,0287
ARI máximo	1,0000
IC 95% (percentílico)	[0,047 ; 1,000]
% de repetições instáveis (ARI < 0,5)	4,50%

Tabela 6 - Estatísticas do ARI na simulação de reamostragem (B = 200).




Figura 9 - Histograma do Índice Rand Ajustado (ARI) nas 200 repetições de reamostragem.

O ARI mediano de 0,9674 indica que, na maioria das repetições, o agrupamento obtido com 80% dos dados concorda fortemente com o agrupamento de referência. Entretanto, o desvio-padrão relativamente alto (0,2015) e o mínimo próximo de zero (0,0287) revelam que uma fração não desprezível das repetições (4,5%) produziu agrupamentos com concordância próxima à esperada ao acaso. Essa instabilidade ocorre tipicamente quando, por sorte da amostragem, um ou ambos os clientes do minúsculo Grupo 1 (apenas 2 clientes na base completa) não são selecionados na amostra de 80% - nesse caso, o algoritmo é forçado a formar três grupos a partir de uma estrutura que, na prática, contém apenas duas grandes massas de dados, tornando a atribuição de rótulos mais arbitrária.

Na análise de estabilidade frente a diferentes sementes de inicialização (30 sementes, base completa), o ARI médio foi de 0,8927 (desvio-padrão 0,2738, mínimo 0,0524) - reforçando que a principal fonte de instabilidade do agrupamento não é a amostragem em si, mas a existência de grupos extremamente pequenos (2 e 16 clientes) cuja composição exata pode variar conforme a inicialização dos centroides.

Já na análise de perturbação (ruído gaussiano de 5% do desvio-padrão de cada variável, aplicado à base completa), o ARI foi de exatamente 1,0000 em todas as 200 repetições. Isso é esperado: como a separação entre os grupos é definida por diferenças de grande magnitude (o Grupo 1 tem, por exemplo, um valor total mediano cerca de 180 vezes maior que o Grupo 0), uma perturbação pequena em relação ao desvio-padrão de cada variável não é suficiente para alterar a atribuição de nenhum cliente a um grupo diferente.

A matriz de coagrupamento, construída em uma subamostra de 300 clientes ao longo das 200 repetições de reamostragem, é apresentada na Figura 10.




Figura 10 - Matriz de coagrupamento (subamostra de 300 clientes, $B = 200$ repetições).

A predominância de tons claros (valores próximos de 1) confirma que a grande maioria dos pares de clientes permanece consistentemente no mesmo grupo ao longo das repetições - o que é esperado, já que o Grupo 0 concentra mais de 99% da base e tende a permanecer coeso. Poucos pares apresentam incerteza intermediária, concentrados nas fronteiras entre os grupos minoritários.

3.7 Interpretação dos grupos e observações atípicas

A Figura 11 apresenta a distribuição dos grupos do K-means em pares de variáveis, permitindo visualizar simultaneamente a separação entre grupos em múltiplas dimensões.




Figura 11 - Grupos do K-means ($K = 3$) representados em pares de variáveis.

Quanto às observações classificadas como ruído pelo DBSCAN (177 clientes, 4,08% da base), a Tabela 7 compara suas estatísticas descritivas com as dos clientes não atípicos.

Variável (média)	Clientes atípicos (ruído)	Clientes não atípicos
Valor Total (£)	22.653,63	1.177,73
Frequência	23,69	3,45

Tabela 7 - Comparação entre clientes atípicos (ruído do DBSCAN) e clientes não atípicos.

Em média, os clientes classificados como ruído gastaram cerca de 19 vezes mais e compraram cerca de 7 vezes mais frequentemente do que os clientes não atípicos. Esse padrão não sugere erro de registro, mas sim um perfil de compra genuinamente diferente - compatível com clientes institucionais, revendedores ou compradores de grande volume. Por esse motivo, esses clientes não devem ser removidos da base, mas sim tratados como um segmento à parte para fins de decisão comercial.

Complementarmente, ao calcular a distância de cada cliente ao centróide do seu próprio grupo (K-means), os 44 clientes mais distantes (top 1%) pertencem majoritariamente aos Grupos 1 e 2 - reforçando que, mesmo dentro dos grupos de alto valor, existe heterogeneidade adicional que uma segmentação mais refinada poderia capturar.

4. Discussão

O principal achado deste trabalho é metodológico antes de ser comercial: a presença de outliers extremos (poucos clientes com valores de compra centenas de vezes maiores que a mediana) domina completamente os resultados dos três métodos de agrupamento testados quando a distância euclidiana é aplicada sobre variáveis padronizadas pelo escore z convencional. Isso se manifesta de três formas observadas nos resultados: (i) o coeficiente de silhueta praticamente constante e muito alto para qualquer K no K-means; (ii) a divisão inicial do dendrograma isolando poucos pontos antes de qualquer segmentação da massa principal; e (iii) grupos do K-means extremamente desbalanceados (99,59% / 0,37% / 0,05% dos clientes).

Esse comportamento é consistente com a literatura sobre agrupamento em dados de varejo: variáveis como valor total gasto e quantidade de itens tendem a seguir distribuições de cauda pesada (poucos clientes concentram uma fração desproporcional do valor transacionado), e a padronização pelo escore z que preserva a forma da distribuição original (não corrige essa assimetria, apenas reescala a variável. Uma transformação logarítmica ou uma padronização robusta (por exemplo, baseada em mediana e IQR) poderia atenuar esse efeito e permitir que os algoritmos capturassem diferenças comportamentais mais sutis dentro da massa principal de clientes — essa é uma limitação assumida deste trabalho e uma sugestão explícita para uma próxima iteração da análise.

Ainda assim, os resultados obtidos têm utilidade prática real: eles demonstram, de forma robusta e replicável (confirmada pela simulação de Monte Carlo), a existência de um pequeno grupo de clientes de altíssimo valor que deveria ser tratado separadamente da base de clientes “comuns” em qualquer análise ou ação comercial subsequente, inclusive em uma futura segmentação mais refinada da massa principal.

Quanto à comparação entre os métodos, o DBSCAN se mostrou o mais adequado à estrutura real dos dados, pois lida explicitamente com observações de densidade muito menor (tratando-as como ruído) sem forçar sua inclusão em um grupo artificial de tamanho 2, como ocorreu no K-means. Por outro lado, o K-means e o hierárquico têm a vantagem de produzir partições completas (sem ruído), o que pode ser preferível quando a empresa deseja atribuir todo cliente a algum segmento, ainda que artificialmente pequeno.

A simulação de Monte Carlo confirmou que o agrupamento de referência é estável frente a pequenas perturbações (ARI = 1,0 em todas as repetições) e razoavelmente estável frente à reamostragem (ARI mediano de 0,97), mas identificou uma vulnerabilidade específica: como o Grupo 1 possui apenas 2 clientes na base completa, tanto a reamostragem quanto a variação de sementes podem ocasionalmente produzir soluções com baixa concordância (ARI próximo de zero em cerca de 4 a 5% das repetições), pois a exclusão ou realocação desses poucos pontos extremos altera substancialmente a partição.

5. Conclusão

Quais padrões foram encontrados? Um padrão dominante de concentração: a grande maioria dos clientes (99,6%) tem comportamento de compra relativamente modesto e homogêneo, enquanto uma pequena fração (entre 0,4% e 4% da base, a depender do método) apresenta valores de compra e frequência muito acima da média, consistentes com clientes institucionais ou revendedores.

Quantos grupos foram considerados adequados? Três grupos para o K-means e para o hierárquico (conforme especificado); dois grupos mais uma categoria de ruído para o DBSCAN.

Qual método apresentou o melhor resultado? Depende do critério: o K-means apresentou a maior silhueta (0,944), mas o DBSCAN apresentou o melhor índice Davies-Bouldin (0,224) e é conceitualmente mais adequado à estrutura de densidade heterogênea da base, por tratar explicitamente as observações atípicas como ruído em vez de forçá-las em grupos artificialmente pequenos.

Quais variáveis mais diferenciam os grupos? Valor Total, Quantidade Total e Produtos Distintos foram as variáveis com maior poder de diferenciação entre os grupos extremos e a massa principal; Frequência diferenciou principalmente o Grupo 2 (alta frequência) dos demais.

Os grupos foram bem separados? Numericamente sim (silhuetas altas), mas essa separação decorre majoritariamente do isolamento de poucos outliers extremos, e não de uma segmentação comportamental refinada da maioria dos clientes; uma ressalva importante na interpretação das métricas.

Os resultados permaneceram estáveis nas simulações? De forma geral sim (ARI mediano de 0,97 na reamostragem, $ARI = 1,0$ na perturbação), mas com uma minoria relevante de repetições instáveis (4,5%) associada à presença de grupos extremamente pequenos.

Qual foi o efeito da amostragem aleatória? Moderado: reduziu ligeiramente a concordância média em relação ao agrupamento de referência e, ocasionalmente, produziu partições divergentes quando os clientes do Grupo 1 não eram selecionados na amostra.

O método apresentou sensibilidade à inicialização? Sim, de forma moderada: o ARI médio entre 30 sementes diferentes foi de 0,893, com mínimo de 0,052, evidenciando que a atribuição de rótulos aos grupos minoritários pode variar conforme a inicialização dos centroides.

Quais observações apresentaram comportamento atípico? 177 clientes (4,08%) foram classificados como ruído pelo DBSCAN, com gasto médio cerca de 19 vezes maior e frequência de compra cerca de 7 vezes maior do que os clientes não atípicos, consistentes com clientes institucionais ou revendedores, não com erros de registro.

Quais limitações estão presentes na análise? (i) A padronização pelo escore z não corrige a assimetria das variáveis, permitindo que outliers extremos dominem o resultado; (ii) duas variáveis (Valor Médio e Quantidade Média por Compra) apresentam correlação muito alta (0,921), sugerindo possível redundância; (iii) o agrupamento hierárquico foi calculado em uma amostra de 1.000 clientes, e não na base completa, por restrição computacional; (iv) a base não contempla informações de recência da última compra, que poderiam enriquecer a segmentação (modelo RFM completo).

Como os resultados poderiam ser utilizados no contexto real? Para direcionar um atendimento diferenciado aos clientes do Grupo 1/Grupo 2 (ou aos classificados como ruído pelo DBSCAN), como contas comerciais dedicadas ou condições comerciais específicas, e para orientar futuras iterações de segmentação da massa principal de clientes, aplicando transformação logarítmica ou padronização robusta para revelar subgrupos comportamentais mais sutis dentro desse grupo majoritário.

Referências

UCI MACHINE LEARNING REPOSITORY. Online Retail Data Set. Disponível em: <https://archive.ics.uci.edu/dataset/352/online+retail>. Acesso em: 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.